

Estudo Dirigido 3

Lucas Silva de Oliveira

1 de junho de 2026

Instituição: UEFS — **Disciplina:** Aprendizado de Máquina e Ciência de Dados —
Professor: Dr. Rodrigo Tripodi Calumby

Em Python:

- Pandas: É a biblioteca principal para manipulação de datasets, ela auxilia nas tarefas básicas de pré-processamento como: deletar colunas, imputar valores ausentes, filtrar dados entre outras funcionalidades.
- Numpy: Biblioteca que permite operações numéricas de limpeza de dados e é frequentemente usado ao lado do Pandas para pré-processamento eficiente em termos de desempenho.
- Scikit-learn: Além dos próprios algoritmos de aprendizado de máquina, a biblioteca fornece um módulo de pré-processamento dedicado que é muito utilizado em fluxos de trabalho.

Exemplo de funções e métodos em Python

```
import pandas as pd
import numpy as np
from sklearn.decomposition import PCA
from sklearn.preprocessing import MinMaxScaler
from sklearn.preprocessing import StandardScaler
from sklearn.preprocessing import LabelEncoder
from sklearn.preprocessing import OneHotEncoder
from sklearn.impute import SimpleImputer

df1 = pd.read_csv("exemplo1.csv")

#----- LIMPEZA DE DADOS -----
#remove elementos ausentes
df1.dropna()

#preenche elementos ausentes
df1.fillna(0)

imputer = SimpleImputer(strategy='mean')
df1[['idade']] = imputer.fit_transform(df1[['idade']])

#remove linhas duplicadas no dataset
df1.drop_duplicates()

#----- INTEGRACAO DE DADOS -----
df2 = pd.read_csv("exemplo2.csv")

pd.merge(df1, df2, on="id")
```

```

pd.concat([df1, df2])

resultado_join = df1.join(df2)

#----- REDUCAO DE DADOS -----

df1 = df1[['idade', 'salario', 'comprou']]

pca = PCA(n_components=2)
X_reduzido = pca.fit_transform(X)

#----- TRANSFORMACAO DE DADOS -----

scaler = MinMaxScaler()
X_norm = scaler.fit_transform(X)

scaler = StandardScaler()
X_pad = scaler.fit_transform(X)

encoder = LabelEncoder()
df1['cidade'] = encoder.fit_transform(df1['cidade'])

hot_encoder = OneHotEncoder()
cidade_codificada = hot_encoder.fit_transform(df1[['cidade']])

```

Na Tabela 1 é possível visualizar algumas das principais funções, métodos e classes que podem auxiliar nas diferentes etapas do pré-processamento de dados em Python.

Etapas	Componentes Utilizados
Limpeza	dropna(), fillna(), SimpleImputer, drop_duplicates(), replace()
Integração	merge(), concat(), join()
Redução	Seleção de atributos, PCA
Transformação	MinMaxScaler, StandardScaler, LabelEncoder, OneHotEncoder

Tabela 1: Principais funções, métodos e classes para pré-processamento de dados em Python

Referências

PYKES, K. *Data Preprocessing: A Complete Guide with Python Examples*. 2025. Acesso em: 30 mai. 2026. Disponível em: <https://www.datacamp.com/blog/data-preprocessing>.

Scikit-learn developers. *Scikit-learn Documentation*. 2026. <https://scikit-learn.org/stable/documentation.html>. Acesso em: 14 mai. 2026.

The Pandas Development Team. *Pandas Documentation*. 2026. Acesso em: 21 mai. 2026. Disponível em: <https://pandas.pydata.org/>.