

Estudo Dirigido 3

Lucas Silva de Oliveira

1 de junho de 2026

Instituição: UEFS — **Disciplina:** Aprendizado de Máquina e Ciência de Dados —
Professor: Dr. Rodrigo Tripodi Calumby

Na sua linguagem de programação e bibliotecas de apoio, investigue quais ferramentas de pré-processamento de dados estão disponíveis. Crie um resumo de componentes de código que permitam executar as tarefas de pré-processamento discutidas em sala: Limpeza, Integração, Redução e Transformação.

Em Python:

- Pandas: É a biblioteca principal para manipulação de datasets, ela auxilia nas tarefas básicas de pré-processamento como: deletar colunas, imputar valores ausentes, filtrar dados entre outras funcionalidades.
- Numpy: Biblioteca que permite operações numéricas de limpeza de dados e é frequentemente usado ao lado do Pandas para pré-processamento eficiente em termos de desempenho.
- Scikit-learn: fornece um módulo de pré-processamento dedicado que é muito utilizado em fluxos de trabalho de aprendizado de máquina.

Exemplo de funções e métodos em Python

```
import pandas as pd
import numpy as np
from sklearn.decomposition import PCA
from sklearn.preprocessing import MinMaxScaler
from sklearn.preprocessing import StandardScaler
from sklearn.preprocessing import LabelEncoder
from sklearn.preprocessing import OneHotEncoder

df1 = pd.read_csv("exemplo1.csv")

#----- LIMPEZA DE DADOS -----
#remove elementos ausentes
df1.dropna()

#preenche elementos ausentes
df1.fillna(0)

#remove linhas duplicadas no dataset
df1.drop_duplicates()

df1.replace("N/A", np.nan)

#----- INTEGRACAO DE DADOS -----
df2 = pd.read_csv("exemplo2.csv")

pd.merge(df1, df2, on="id")
```

```

pd.concat([df1, df2])

resultado_join = df1.join(df2)

#----- REDUCAO DE DADOS -----

df1 = df1[['idade', 'salario', 'comprou']]

pca = PCA(n_components=2)
X_reduzido = pca.fit_transform(X)

#----- TRANSFORMACAO DE DADOS -----

scaler = MinMaxScaler()
X_norm = scaler.fit_transform(X)

scaler = StandardScaler()
X_pad = scaler.fit_transform(X)

encoder = LabelEncoder()
df1['cidade'] = encoder.fit_transform(df1['cidade'])

hot_encoder = OneHotEncoder()
cidade_codificada = hot_encoder.fit_transform(df1[['cidade']])

```

Etapa	Componentes Utilizados
Limpeza	dropna(), fillna(), drop_duplicates(), replace()
Integração	merge(), concat(), join()
Redução	Seleção de atributos, PCA
Transformação	MinMaxScaler, StandardScaler, LabelEncoder, OneHotEncoder

Tabela 1: Ferramentas de pré-processamento em Python